# 低秩分支细节：y = Wx + (alpha/r) B A Dropout(x)

## 自注意力目标线性层：rank=4

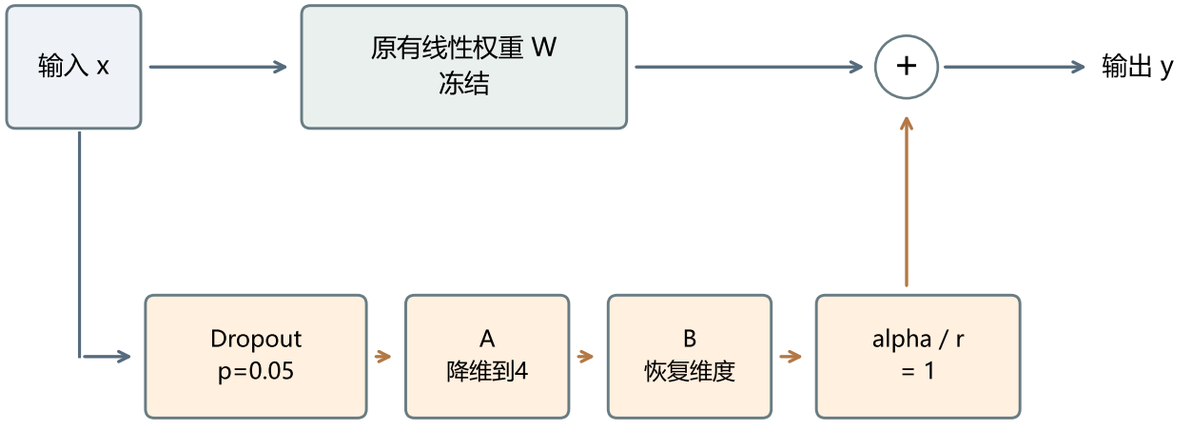


r=alpha=4；A：r×d_in，B：d_out×r；仅更新A、B

## 交叉注意力目标线性层：rank=8

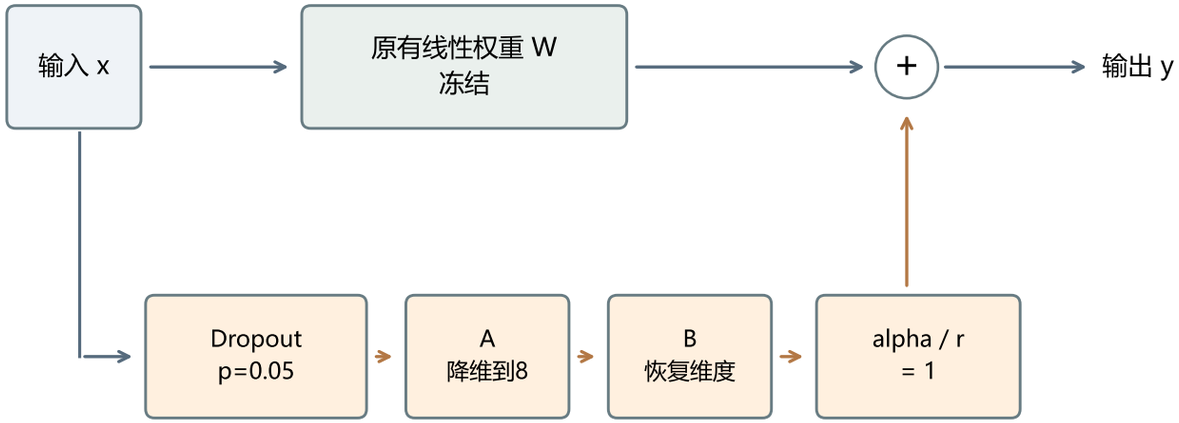


r=alpha=8；A：r×d_in，B：d_out×r；仅更新A、B

Q、K、V、Out均按对应注意力类型使用上述配置；推理时显式eval，Dropout关闭。